

Vidya Capture: arquitetura, comparação e ganhos de produtividade em um software livre para digitalização de acervos

[Nome do(a) autor(a)]¹

¹ Laboratório Multiusuário de Humanidades Digitais e Inovação (LAMUHDI), Museu Campos Gerais, Universidade Estadual de Ponta Grossa (UEPG). E-mail: [inserir e-mail institucional].

RESUMO

A digitalização de acervos históricos em universidades públicas brasileiras enfrenta um duplo entrave: a dependência de softwares proprietários estrangeiros, com licenças onerosas e formatos fechados, e a fragmentação de ferramentas livres, que obriga operadores a transitar imagens entre múltiplos programas para captura, correção geométrica, reconhecimento de caracteres (OCR) e empacotamento arquivístico. Este artigo apresenta o Vidya Capture, software livre desenvolvido no Laboratório Multiusuário de Humanidades Digitais e Inovação (LAMUHDI) da Universidade Estadual de Ponta Grossa (UEPG), que unifica em uma única estação de trabalho a captura fotográfica agnóstica de hardware, a correção geométrica não destrutiva, a calibração de parâmetros assistida por inteligência artificial e a selagem criptográfica de pacotes de preservação. Descreve-se a arquitetura modular do sistema, compara-se seu desempenho funcional a soluções consolidadas no mercado — Zeutschel, Atiz, CZUR e ScanTailor Advanced — e discutem-se os ganhos de produtividade observados em uso. Argumenta-se que ferramentas livres bem arquitetadas podem reduzir a dependência tecnológica de instituições de memória do Sul Global sem abandonar o rigor arquivístico exigido por repositórios institucionais.

Palavras-chave: Humanidades Digitais; preservação digital; software livre; digitalização de acervos; visão computacional.

ABSTRACT

Digitizing historical collections at Brazilian public universities faces two obstacles: dependence on proprietary foreign software with costly licenses and closed formats, and fragmentation of free tools that forces operators to move images across multiple programs for capture, geometric correction, OCR and archival packaging. This paper presents Vidya Capture, free software developed at the Laboratory for Digital Humanities and Innovation (LAMUHDI), State University of Ponta Grossa (UEPG), unifying hardware-agnostic capture, non-destructive geometric correction, AI-assisted parameter calibration and cryptographic sealing of preservation packages in a single workstation. The system's modular architecture is described and compared to established market solutions — Zeutschel, Atiz, CZUR and ScanTailor Advanced — and resulting productivity gains are discussed.

Keywords: Digital Humanities; digital preservation; free software; archival digitization; computer vision.

1. Introdução

As Humanidades Digitais transcendem a mera conversão de suportes analógicos para formatos binários: constituem um campo interdisciplinar que funde a investigação das ciências humanas a metodologias computacionais, exigindo rigor técnico na preservação, catalogação e difusão do patrimônio histórico [1]. No Brasil, levantamentos recentes sobre cultura digital indicam que a digitalização deixou de ser um projeto pontual para se tornar política institucional, ainda que sob restrições orçamentárias persistentes [2].

O Laboratório Multiusuário de Humanidades Digitais e Inovação (LAMUHDI), sediado no Museu Campos Gerais da Universidade Estadual de Ponta Grossa (UEPG), exemplifica esse movimento: conduz a digitalização de mais de 2.200 volumes do jornal Diário dos Campos (década de 1930) e o restauro do acervo fotográfico Foto Tanko, além de orientar mais de vinte espaços públicos associados a universidades paranaenses [3]. Essas operações são sustentadas por editais competitivos, como a Lei Paulo Gustavo e fomentos do

Instituto Brasileiro de Museus, além de parcerias com a Fundação Araucária e a Secretaria de Estado da Ciência, Tecnologia e Ensino Superior do Paraná [4].

O parque tecnológico do laboratório — que combina scanners planetários, sistemas de berço em V e digitalizadores de microfilme de diferentes fabricantes — expõe um gargalo comum às Humanidades Digitais no Sul Global: a dependência de ecossistemas de software proprietários, com licenças onerosas e formatos frequentemente fechados, somada à fragmentação de ferramentas livres entre programas distintos de captura, correção geométrica, OCR e empacotamento. Foi nesse cenário que se desenvolveu o Vidya Capture, software livre concebido como núcleo unificador das estações de digitalização do LAMUHDI, em complemento ao Vidya, pipeline de inteligência artificial do mesmo laboratório dedicado ao enriquecimento semântico e à descrição arquivística automatizada [5]. Este artigo descreve a arquitetura do Vidya Capture, compara-o a soluções consolidadas no mercado e discute os ganhos de produtividade observados em uso.

2. Arquitetura do Vidya Capture

O Vidya Capture é escrito em Python, com interface gráfica em PyQt5 e processamento de imagem em OpenCV, organizados em arquitetura modular na qual operações de entrada/saída intensivas não bloqueiam a visualização em tempo real (live view) oferecida ao operador.

Correção geométrica não destrutiva. O sistema preserva intacta no disco a matriz fotográfica original (RAW ou PNG); qualquer intervenção — recorte, marcação de perspectiva — é registrada como coordenadas em um arquivo de metadados acessório (sidecar JSON), permitindo reajustes futuros sem nova manipulação do documento físico. O módulo de recorte automático aplica desfoque gaussiano, limiarização de Otsu e operações morfológicas para diferenciar margens do papel e unir virtualmente rasgos antes de calcular o polígono de corte; para periódicos de paginação irregular, admite-se a definição de polígonos de múltiplos vértices. O alinhamento de página (deskew) combina duas abordagens — regressão sobre o contorno físico do papel e cálculo do horizonte das linhas tipográficas —, enquanto o módulo de planificação (dewarp) corrige a deflexão da lombada do livro, com uma trava de planicidade que protege páginas já corrigidas de cisalhamento accidental.

Orquestração de hardware. O sistema interroga o barramento USB e comunica-se de forma agnóstica com câmaras DSLR via protocolo PTP (gphoto2), incluindo o levantamento do espelho do visor para live view contínuo sem desgaste térmico em turnos longos; com câmaras industriais e webcams via Video4Linux2, permitindo a injeção de codecs diretamente no nó do dispositivo; e com scanners planetários e de mesa via backend SANE, parametrizando resolução e correções analógicas.

Calibração assistida por inteligência artificial. Em vez do ajuste manual e iterativo de limiares de binarização — processo historicamente custoso e sujeito a heterogeneidade de qualidade —, o módulo de calibração coleta amostras estratificadas ao longo da sessão de trabalho, recebe do operador a marcação de poucos gabaritos (ground truth) e delega a um motor baseado em algoritmos genéticos (Optuna) a busca por hiperparâmetros ótimos de desfoque, dilatação morfológica e equalização adaptativa de histograma (CLAHE). A função objetivo dessa busca é a taxa de confiança do reconhecimento óptico de caracteres, calculada via API nativa do Tesseract 5 [6], travando-se a melhor combinação para todo o lote.

Cadeia de custódia. No momento da captura, o sistema pode calcular e selar a assinatura criptográfica SHA-256 da matriz original. Todo evento de intervenção geométrica é registrado segundo o padrão PREMIS [7] em um manifesto de projeto e embutido nos metadados do PDF/A-2b final (ISO 19005). O empacotamento segue a especificação BagIt — RFC 8493 [8] —, com exportação complementar em TSV mapeada ao Dublin Core, permitindo importação direta em repositórios como Tainacan, Omeka S, AtoM e DSpace.

3. Comparativo com soluções de mercado

O Vidya Capture não compete com a ótica e a velocidade de equipamentos como os scanners planetários Zeutschel, cuja linha OS combina sensores CMOS de alta resolução a softwares proprietários como o Omniscan, com destaque para a tecnologia patenteada Perfect Book 3D de correção topográfica da curvatura do livro [9, 10]. Seu diferencial está na camada de software: oferece, de forma agnóstica a hardware, rotinas análogas de correção geométrica e auditoria PREMIS que a Zeutschel restringe aos compradores de seu equipamento de elite.

A Atiz popularizou o berço em V associado a câmaras DSLR pareadas, mas distribui o software em duas aplicações separadas — BookDrive Capture, para controle de câmaras, e BookDrive Editor Pro, para recorte e binarização —, exigindo a exportação de milhares de imagens entre etapas e sem empacotamento BagIt ou hashes nativos [11, 12]. O Vidya Capture unifica captura e edição em uma única interface síncrona. Scanners planetários de menor custo, como os da linha CZUR, adotam paradigma de “caixa preta”, sem rastro auditável das decisões de corte e planificação — lacuna que a abordagem não destrutiva do Vidya Capture supre.

Já o ScanTailor Advanced, pipeline livre de referência para laboratórios com poucos recursos, oferece algoritmos sólidos de binarização (Otsu, Sauvola, Wolf), mas teve o desenvolvimento essencialmente interrompido em 2020, não realiza OCR nem se comunica com hardware de captura, e exige ajuste manual e iterativo de parâmetros de sensibilidade [13, 14]. A Tabela 1 resume esse comparativo.

Tabela 1 — Comparativo funcional entre ecossistemas de digitalização

Funcionalidade / Ecossistema	Vidya Capture	Zeutschel Omniscan	Atiz BookDrive Pro	ScanTailor Advanced
Licenciamento	Código aberto	Comercial, vinculado ao hardware	Comercial, vinculado ao hardware	Código aberto (desenvolvimento interrompido)
Captura + edição	Unificadas, em tempo real	Unificadas	Bipartidas (dois aplicativos distintos)	Apenas edição pós-captura
Integração de hardware	Agnóstica (PTP/gphoto2, V4L2, SANE)	Dedicada (sensores próprios)	PTP dedicado (Canon/Sony)	Nenhuma
OCR nativo	Sim (Tesseract 5, API C++)	Módulos opcionais	Não	Não
Calibração de parâmetros	Automática (IA / Optuna)	Automática (alvo de calibração)	Manual / perfis estáticos	Manual (sliders)
Selagem e empacotamento	SHA-256 + PREMIS + BagIt nativos	Suporte parcial (via Kitodo)	Ausente	Ausente

Fonte: elaborado pelo(a) autor(a) [9–14].

4. Ganhos de produtividade

O fluxo de trabalho legado mais comum nos laboratórios — captura em um programa, transferência física das imagens, processamento geométrico em outro programa, exportação de matrizes, OCR em um terceiro software e catalogação manual — multiplica a leitura e a escrita em disco de lotes que somam dezenas de gigabytes por livro. O Vidya Capture elimina essa redundância por meio de um pipeline em memória: ao exportar, a matriz fotográfica é carregada uma única vez em RAM, onde a mesma instância sofre recorte, correção de inclinação e binarização via OpenCV, é passada por ponteiro ao Tesseract para extração de texto e, por fim, embutida em um PDF/A normalizado, sem etapas intermediárias em disco.

Um segundo ganho atende a um erro operacional recorrente: ao virar inadvertidamente duas folhas de uma vez, o operador só percebe a falha centenas de fotografias depois, o que tradicionalmente exigiria renomear manualmente todo o lote subsequente. O algoritmo de

“deslocamento em cascata” do Vidya Capture reorganiza automaticamente timestamps e nomes de arquivo ao inserir a captura faltante, preservando a ordem lógica da obra sem intervenção manual.

Por fim, a calibração assistida por IA substitui o ajuste manual e repetitivo de limiares de binarização — fonte conhecida de fadiga decisória e de heterogeneidade de qualidade ao longo de um turno de trabalho — por uma busca automatizada que mede objetivamente a legibilidade resultante via confiança do OCR.

5. Considerações finais

A obrigatoriedade, em licitações públicas, de adquirir equipamentos e licenças proprietárias estrangeiras constitui barreira recorrente à expansão de repositórios universitários brasileiros. Ao permitir que hardware genérico e de baixo custo alcance rigor arquivístico equiparável a sistemas de alto custo, o Vidya Capture libera recursos institucionais para bolsas de pesquisa e restauro preventivo de acervos, ao mesmo tempo em que sua natureza de código aberto facilita auditoria e investigação acadêmica em visão computacional. Seu desenvolvimento em conjunto com o Vidya — pipeline de inteligência artificial do mesmo laboratório, dedicado à descrição arquivística automatizada [5] — aponta para um ecossistema integrado, no qual a mesma instituição cobre o ciclo completo da digitalização: da captura física à descrição semântica do acervo. A continuidade deste trabalho inclui a publicação do código-fonte do Vidya Capture e a avaliação sistemática de seus ganhos de produtividade em outros laboratórios paranaenses associados ao LAMUHDI.

Referências

- [1] Humanidades digitais e estudos clássicos: ferramentas de difusão e construção do conhecimento histórico. Revista Brasileira de História (SciELO). Disponível em: <https://www.scielo.br/j/rbh/a/bYz8Hkd9scLNYWhz8Yc8h7r/?lang=pt>. Acesso em: 27 jun. 2026.
- [2] CGI.BR — COMITÊ GESTOR DA INTERNET NO BRASIL. TIC Cultura 2024. Disponível em: https://cgi.br/media/docs/publicacoes/2/pt/20251030164910/tic_cultura_2024_livro_eletronico.pdf. Acesso em: 27 jun. 2026.
- [3] UEPG — UNIVERSIDADE ESTADUAL DE PONTA GROSSA. O Laboratório Multiusuário de Humanidades Digitais e Inovação (LAMUHDI). Disponível em: <https://www2.uepg.br/museu/o-laboratorio-multiusuario-de-humanidades-digitais-e-inovacao-lamuhdi/>. Acesso em: 27 jun. 2026.
- [4] UEPG — UNIVERSIDADE ESTADUAL DE PONTA GROSSA. Museu Campos Gerais recebe R\$ 400 mil para digitalização de acervos. Disponível em: <https://www.uepg.br/mcg-digitalizacao/>. Acesso em: 27 jun. 2026.
- [5] MIGLIORINI FILHO, Cloter; MACHADO, Julia Graciela; SILVA, Edson Armando; SCOCZYNSKI, Marcella. Vidya: An AI-Driven Modular Pipeline for Archival Automation and Semantic Metadata Enrichment. arXiv:2605.16338, 2026. Disponível em: <https://arxiv.org/abs/2605.16338>. Acesso em: 27 jun. 2026.
- [6] TESSERACT OCR. Improving the quality of the output. Disponível em: <https://tesseract-ocr.github.io/tessdoc/ImproveQuality.html>. Acesso em: 27 jun. 2026.
- [7] LIBRARY OF CONGRESS. PREMIS: Preservation Metadata Implementation Strategies. Disponível em: <https://www.loc.gov/standards/premis/>. Acesso em: 27 jun. 2026.
- [8] IETF. RFC 8493: The BagIt File Packaging Format (V1.0). Disponível em: <https://www.rfc-editor.org/rfc/rfc8493>. Acesso em: 27 jun. 2026.
- [9] ZEUTSCHEL GMBH. Digitization software. Disponível em: <https://www.zeutschel.de/en/software/>. Acesso em: 27 jun. 2026.
- [10] GENUS. Zeutschel OS HQ. Disponível em: <https://genus.uk/product/zeutschel-os-hq/>. Acesso em: 27 jun. 2026.
- [11] ATIZ. Which book scanning is right for you?. Disponível em: <https://www.atiz.com/whichbookdrive/>. Acesso em: 27 jun. 2026.
- [12] ATIZ. Software — Atiz BookDrive Mini 2. Disponível em: <https://mini2.atiz.com/software/>. Acesso em: 27 jun. 2026.
- [13] 4LEX4. scantailor-advanced: README.md. GitHub. Disponível em: <https://github.com/4lex4/scantailor-advanced/blob/master/README.md>. Acesso em: 27 jun. 2026.
- [14] 4LEX4. Smoothing and threshold methods, current version of the program. Issue #110, GitHub. Disponível em: <https://github.com/4lex4/scantailor-advanced/issues/110>. Acesso em: 27 jun. 2026.